



Bài 7

TRIỂN KHAI VÀ TỐI ƯU INFERENCE

CƠ BẢN VỚI ONNX

Giảng viên: ThS. Lê Thị Thùy Trang

Email: tranglth@dainam.edu.vn

Điện thoại: 0966730396

1. Phân biệt được Training với Inference trong quy trình phát triển mô hình học sâu
2. Trình bày được vai trò của ONNX và ONNXRuntime trong việc chuyển mô hình từ môi trường training sang môi trường deployment
3. Giải thích được các chỉ số benchmark cơ bản
4. Đề xuất khả năng triển khai mô hình dựa trên kết quả benchmark




1. Nhắc lại kiến thức
2. Training vs Inference
3. ONNX, ONNXRuntime
4. Benchmark và đánh giá khả năng triển khai
5. Thực hành





CASE STUDY






- ❖ **MIT Indoor Scene 67** (thường gọi tắt là MIT-67) là một bộ dữ liệu chuẩn (benchmark) nổi tiếng trong lĩnh vực Thị giác máy tính, được phát triển bởi Viện Công nghệ Massachusetts (MIT). Bộ dữ liệu này chuyên dùng để huấn luyện và đánh giá các mô hình AI nhận diện bối cảnh không gian trong nhà.



15.620 bức ảnh

67 lớp

Mỗi lớp chứa tối thiểu
100 bức ảnh.







TRAINING VS INFERENCE



TRAINING VS INFERENCE





TRAINING VS INFERENCE



- ❖ **Deep learning inference** is the process of using a trained DNN model to make predictions against previously unseen data. As explained above, the DL training process actually involves inference, because each time an image is fed into the DNN during training, the DNN attempts to classify it. Given this, deploying a trained DNN for inference can be trivial. You could, for example, simply make a copy of a trained DNN and start using it “as is” for inference. However, for reasons explained below, **a trained DNN is often modified and simplified before being deployed for inference.**
- ❖ Sometimes the use case requires that **inference run very fast or at very low power.** For example, a self-driving car must be able to detect and respond within milliseconds in order to avoid an accident. And a battery-operated drone designed to follow a target or land in your hand has to be power-efficient to maximize flight time.

TRAINING VS INFERENCE


- ❖ Sự khác biệt giữa các yêu cầu trong môi trường nghiên cứu và môi trường triển khai sản phẩm?



TRAINING VS INFERENCE

❖ Vấn đề của file .pt?

- Cần code định nghĩa model
- Cần PyTorch
- Cần đúng version thư viện
- Khó chạy ngoài Python
- Chưa tối ưu riêng cho inference







ONNX, ONNX RUNTIME




- ❖ **Open Neural Network Exchange (ONNX):** là công cụ mã nguồn mở cung cấp định dạng chuẩn để biểu diễn chung cho các mô hình học máy khác nhau.
- ❖ Thay vì đóng vai trò là công cụ chuyển đổi mã nguồn giữa các thư viện, ONNX cung cấp một định dạng biểu diễn mô hình thống nhất. Cơ chế này giúp tách biệt hoàn toàn giai đoạn phát triển khỏi giai đoạn vận hành.




❖ Cấu trúc 1 tập tin ONNX




❖ Quy trình chuyển đổi mô hình sang định dạng ONNX




- ❖ **ONNX Runtime (ORT):** là một High-performance Inference Engine (tạm dịch: trình suy luận hiệu năng cao) được thiết kế chuyên biệt để vận hành các mô hình AI trong môi trường thực tế.
- ❖ ONNX Runtime hoạt động như một cầu nối kĩ thuật, nhận đầu vào là các mô hình định dạng chuẩn ONNX và thực thi chúng trên hạ tầng phần cứng vật lí.
- ❖ Mục tiêu chính của ORT là tối **ưu hóa tốc độ xử lí** và **đảm bảo tính tương thích trên đa nền tảng**.




❖ Kiến trúc ONNX Runtime (ORT)



❖ Các kỹ thuật tối ưu hoá ONNX và ONNX Runtime (ORT)



- ❖ Khi inference dùng `model.eval()` hay `model.train()`? Tại sao?




BENCHMARK & ĐÁNH GIÁ KHẢ NĂNG TRIỂN KHAI





PyTorch


**ONNX nhanh hơn
PyTorch.
Nhanh hơn như nào?**




ONNX

- ❖ Benchmark là cách chúng ta lấy số liệu một cách hệ thống để đưa ra kết luận có căn cứ.
- ❖ Benchmark trả lời các câu hỏi:
 - Có chạy được không? → Consistency test
 - Chạy nhanh không? → Latency
 - Xử lý được nhiều không? → Throughput
 - Có đủ nhẹ để deploy không? → Model size / memory

❖ Nguyên tắc đo benchmark công bằng



- ❖ Latency là thời gian để mô hình xử lý xong một lượt inference
- ❖ Latency thường tăng khi batch size tăng



Metric	Ý nghĩa
mean_latency_ms	Trung bình thời gian qua nhiều lần đo
median_latency_ms	Trung vị – ít bị ảnh hưởng bởi outlier hơn mean
p95_latency_ms	95% các lượt chạy nhanh hơn hoặc bằng giá trị này

❖ **Throughput** đo sức xử lý tổng thể.

❖ Ví dụ: `batch_size = 8`:

$$\text{Throughput} = 8 / 0.4 = \mathbf{20} \text{ ảnh/giây}$$


❖ Trade - off giữa latency và throughput

Batch size	Latency/batch	Throughput
1	80ms	12.5 img/s
4	200ms	20 img/s
8	350ms	22.8 img/s

Và 1 metric bị lãng quên




HOW TO READ BENCHMARK?



Runtime	Batch size	Mean latency (ms)	P95 latency (ms)	Throughput (img/s)	Size (MB)
PyTorch	1	95	115	10.5	343
ONNX Runtime	1	72	88	13.9	298
PyTorch	4	290	340	13.8	343
ONNX Runtime	4	230	275	17.4	298
PyTorch	8	540	620	14.8	343
ONNX Runtime	8	450	510	17.8	298

THỰC HÀNH









Thank You!

DAI NAM
UNIVERSITY